DeiT의 Attention Sink 완화를 위한 게이트 기반 Self-Attention 구조*

최성하[1] 이영호[1] 이혁수[1]
[1]경희대학교 컴퓨터공학과
sunghac@khu.ac.kr, dldudgh329@khu.ac.kr, dlgurtn112@khu.ac.kr

A Gated Self-Attention Mechanism for Mitigating Attention Sink in DeiT

Sungha Choi[1] Youngho Lee[1] Hyeoksu Lee[1]
[1]Department of Computer Engineering, Kyung Hee University

요 약

본 연구는 Vision Transformer 계열 모델인 DeiT(Data-efficient Image Transformer)의 추가 학습 과정에서 발생하는 attention sink 현상을 완화하기 위한 게이트 기반 self-attention 구조를 제안한다. Attention sink는 학습이 진행됨에 따라 정보량이 적은 특정 토큰에 어텐션 가중치가 비정상적으로 집중되는 현상으로, softmax의 합이 1이 되어야 한다는 정규화 제약으로 인해 어텐션 헤드가 "no-op"을 학습하는 과정에서 발생한다. 본 연구에서는 softmax 적용 후 multi-head 출력을 concat한 직후에 입력 의존적 시그모이드 게이트를 부착하여 어텐션 출력을 헤드 단위로 동적으로 조절할 수 있도록 한다. DeiT-Small을 사용한 실험에서 제안 구조는 baseline과 유사한 분류 정확도를 유지하면서, 어텐션 맵 시각화를 통해 sink 토큰에 흩어져 있던 어텐션이 의미 있는 객체 영역의 패치 토큰으로 보다 응집되어 재분배됨을 정성적으로 확인하였다.

1. 서 론

최근 컴퓨터 비전 분야에서 Transformer 기반 모델은 합성곱 신경망(CNN)을 대체할 수 있는 강력한 대안으로 자리 잡고 있다. Vision Transformer(ViT)[1]는 이미지를 패치 단위로 분할하여 self-attention 기반의 처리를 수행함으로써 대규모 데이터셋에서 우수한 성능을 입증하였으며, Touvron 등이 제안한 DeiT(Data-efficient Image Transformer)[2]는 distillation token과 강한 데이터 증강을 활용하여 ImageNet만으로도 경쟁력 있는 성능을 달성함으로써 Transformer 기반 비전 모델의 실용성을 크게 확장하였다.

그러나 이러한 모델을 사전 학습 완료 이후에도 추가로 미세조정(fine-tuning)하는 과정에서, 일부 토큰에 어텐션이 비정상적으로 집중되는 attention sink 현상이 관찰된다. Attention sink는 본래 LLM 분야에서 Xiao 등[3]이 처음 명명한 개념으로, 의미적으로 정보량이 적은 토큰(예: 시작 토큰)에 어텐션 가중치가 과도하게 할당되는 현상을 일컫는다. Vision Transformer 계열에서도 유사한 현상이 보고되었으며, Darcet 등[4]은 ViT의 feature map에서 발견되는 high-norm artifact 토큰이 attention sink 역할을 한다고 분석한 바 있다.

본 연구의 동기는 사전학습된 DeiT-Small을 추가 학습할 때, 모델이 정보량이 풍부한 객체 영역의 패치보다 정보량이 적은 배경 영역의 sink 토큰을 강화하는 방향으로 어텐션이 편향되는 현상을 관찰한 데 있다. 이는 softmax가 항상 합이 1이 되도록 강제하는 정규화 특성으로 인해, 어텐션 헤드가 "아무것도 출력하지 않을" 자유도를 갖지 못하기 때문에 발생한다[5]. 즉, 어텐션 헤드가 특정 쿼리에 대해 어떠한 키와도 강하게 매칭되기를 원하지 않는 상황에서도, sum-to-one 제약 때문에 의미 없는 토큰이 "기본 출력처(default sink)"로 사용된다.

이러한 문제를 해결하기 위해 본 연구는 선행 연구에서 제안된 gated attention 구조[7]를 DeiT-Small 기반 비전 Transformer에 적용하고, 이미지 분류 환경에서 attention sink 완화 가능성을 분석한다. 이를 위해 SDPA(Scaled Dot Product Attention) 이후 sigmoid gating을 도입한 gated DeiT와 baseline DeiT를 비교하여 분류 성능, attention sink 지표, attention map 변화를 함께 검토하였다. 실험 결과, gated DeiT는 baseline과 유사한 분류 성능을 유지하면서 특정 토큰으로 attention이 과도하게 집중되는 현상을 완화하였다. 따라서 본 연구의 기여는 LLM에서 제안된 gated attention의 효과를 DeiT-Small 기반 이미지 분류 환경에서 실험적으로 검토하고, 비전 Transformer에서도 attention sink 완화 가능성이 있음을 보인 데 있다.

2. 관련 연구

2.1 Attention Sink 현상

Attention sink는 Xiao 등[3]이 streaming LLM 환경에서 처음 명명한 현상으로, 시퀀스의 초기 토큰에 어텐션 가중치가 비정상적으로 집중되는 패턴을 의미한다. 이들은 시작 토큰의 KV 캐시를 보존함으로써 window attention의 성능을 회복할 수 있음을 보였다. Gu 등[6]은 attention sink가 사전학습 과정에서 점진적으로 발생함을 실증적으로 분석하고, sink가 일종의 key bias로 작동함을 보였으며, softmax의 정규화 의존성이 이러한 현상의 근본 원인임을 지적하였다.

2.2 Vision Transformer에서의 Sink 현상

Vision Transformer 분야에서는 Darcet 등[4]이 supervised 및 self-supervised 방식으로 학습된 ViT의 feature map에서 high-norm을 갖는 artifact 토큰을 발견하고, 이러한 토큰이 정보량이 적은 배경 패치 영역에서 발생하여 어텐션 가중치를 흡수하는 sink 역할을 함을 분석하였다. 이들은 학습 가능한 register 토큰을 추가하여 이러한 현상을 완화할 수 있음을 보였다. 그러나 register 토큰 추가 방식은 입력 시퀀스 길이를 늘려 연산량을 증가시키는 한계가 있다.

2.3 게이트 기반 Attention 변형

Bondarenko 등[5]은 BERT 및 ViT의 양자화 관점에서 outlier 활성치가 어텐션 헤드의 "no-op" 학습 과정에서 발생함을 분석하고, clipped softmax와 gated attention의 두 가지 완화 방법을 제안하였다. 또한 최근 Qiu 등[7]은 sigmoid gating을 SDPA 출력에 적용함으로써 LLM에서 attention sink 현상을 거

* 본 연구는 과학기술정보통신부 및 정보통신기획평가원의 2026 년도 SW 중심대학사업의 결과로 수행되었음(2023-0-00042).

의 제거할 수 있음을 보고하였다. 본 연구는 이러한 게이트 기반 접근을 DeiT에 적용하여 비전 도메인에서의 attention sink 완화 효과를 검증한다.

3. 제안 방법

3.1 기반 모델

본 연구의 기반 모델로는 약 22M 파라미터를 갖는 DeiT-Small을 사용한다. 이 모델은 12개의 Transformer encoder layer로 구성되며, 각 layer는 [LayerNorm → Multi-Head Self-Attention(MHSA) → Residual → LayerNorm → MLP → Residual]의 표준 구조를 따른다. 입력 이미지(224×224)는 16×16 크기의 patch로 분할되어 총 196개의 patch token으로 변환되며, 여기에 클래스 정보를 집계하는 CLS token이 추가되어 총 197개의 토큰이 모델에 입력된다.

3.2 Attention Sink 문제

표준 self-attention은 각 행의 합이 1이 되는 softmax 정규화를 사용하므로, 어텐션 헤드는 모든 쿼리 위치에 대해 반드시 어떤 키 위치에 확률 질량을 배분해야 한다. 학습이 진행됨에 따라 일부 헤드는 특정 쿼리에 대해 어떠한 키와도 강하게 매칭되기를 원하지 않는 상황에 직면하지만, sum-to-one 제약으로 인해 정보량이 적은 토큰(코너 패치, 균일한 배경 패치 등)에 부득이하게 확률 질량을 배분하게 된다. 이러한 "기본 출력처"가 점차 강화되어 attention sink로 발전하며, 특히 후반 layer에서 두드러지게 나타난다.

3.3 Gated Multi-Head Attention

본 연구에서는 softmax의 sum-to-one 제약을 우회하기 위해, softmax를 적용하여 헤드별 출력을 계산한 뒤 multi-head를 concat한 직후 단계에서 입력 의존적 시그모이드 게이트를 적용하는 구조를 제안한다. 제안 구조는 다음과 같이 정의된다.

$$A_i = softmax(Q_i K_i^T / \sqrt{d_k}) \cdot V_i$$
$$H = Concat(A_1, A_2, \ldots, A_h)$$
$$g = \sigma(X \cdot W_g + b_g)$$
$$Output = (g \odot H) \cdot W_o$$

여기서 A_i는 i번째 헤드의 어텐션 출력, H는 모든 헤드를 concat한 결과이며, W_g와 b_g는 학습 가능한 게이트 파라미터이다. 시그모이드 게이트 $g \in [0,1]$은 concat된 multi-head 출력의 각 차원을 입력에 따라 동적으로 조절한다. 게이트 값이 0에 가까울 경우 해당 차원의 출력이 억제되어 헤드가 "no-op"을 수행할 수 있게 되며, 이를 통해 어텐션 헤드가 sink 토큰에 의존하지 않고 자연스럽게 출력 강도를 학습할 수 있다. 추가 게이트 파라미터는 d×d + d로, DeiT-Small 기준 1% 미만의 파라미터 증가에 그쳐 매우 경량이다.

3.4 Attention 시각화 방법

Sink 현상을 시각화하기 위해, 각 layer에서 197×197 attention matrix를 추출한 뒤 CLS token이 각 patch token을 바라보는 196차원 벡터를 14×14 grid로 재배치하여 attention map으로 시각화한다.

3.5 학습 설정

ImageNet으로 사전학습된 DeiT-Small을 baseline으로 사용하고, 동일한 데이터셋과 하이퍼파라미터로 baseline(게이트 미적용)과 제안 모델(게이트 적용)을 각각 추가 미세조정하였다. 학습 설정은 다음과 같다: epochs 100, batch size 128, optimizer Adam, 학습률 1e-4, early stopping patience 3, min_delta 0.001. 게이트 모델의 경우 게이트 출력에 대한 정규화 손실로 gate_lambda 0.01을 추가로 적용하였다. Early stopping에 의해 두 모델 모두 epoch 5에서 학습이 종료되었다.

4. 실험 결과

4.1 정량적 성능 비교

표 1은 baseline(게이트 미적용)과 제안 모델(Gated)의 학습 종료 시점 성능을 비교한 결과이다. 두 모델 모두 동일한 하이퍼파라미터와 early stopping 조건에서 학습되었으며, 분류 정확도는 두 모델이 매우 유사한 수준을 보였다(baseline 0.821, gated 0.807). 이는 제안한 게이트 구조가 추가 파라미터를 도입함에도 불구하고 baseline의 분류 성능을 거의 보존함을 의미한다. 본 연구의 주된 기여는 정량적 정확도 개선보다는, 다음 절에서 보이는 어텐션 분포의 정성적 개선과 sink 현상 완화에 있다.

표 1. DeiT-Small baseline과 Gated 모델의 학습 결과 비교

지표	Baseline	Gated	Δ
Best Test Acc.	0.821	0.807	−0.014
Train Acc.	0.972	0.971	−0.001
Train Loss	0.096	0.098	+0.002
Stopped Epoch	5	5	—
Gate Loss	—	5.4e−4	—

4.2 학습 곡선 비교

그림 1, 2는 baseline과 gated 모델의 학습 메트릭이다. 두 모델 모두 train loss가 epoch 0에서 빠르게 하강하여 epoch 5에서 약 0.1 수준으로 수렴하였고, train accuracy는 약 0.97에 도달하였다. Test accuracy는 epoch 2에서 최고치를 기록한 후 early stopping으로 종료되었다. Gated 모델의 gate_loss는 4.7e−4에서 5.4e−4 수준으로 점진적으로 증가하는 양상을 보였다.

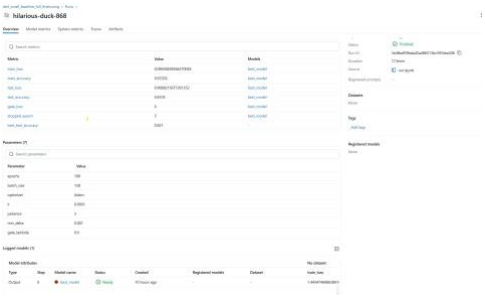


그림 1. Baseline(게이트 미적용) 학습 메트릭

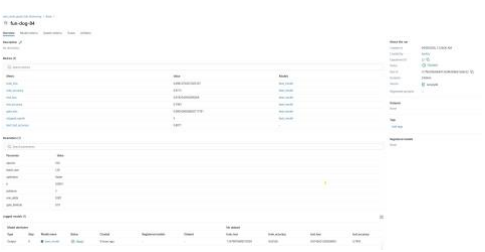


그림 2. Gated 모델의 학습 메트릭

4.3 Run 결과 요약

그림 3, 4는 두 모델의 MLflow run overview이다. Baseline은 17.6분, gated 모델은 24.8분의 학습 시간이 소요되었다.

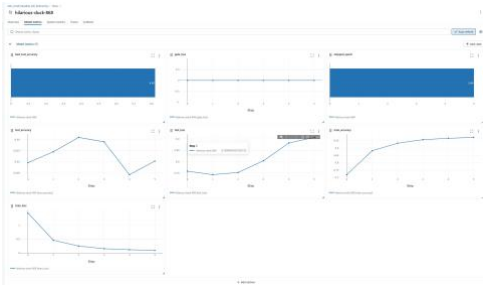


그림 3. Baseline run overview

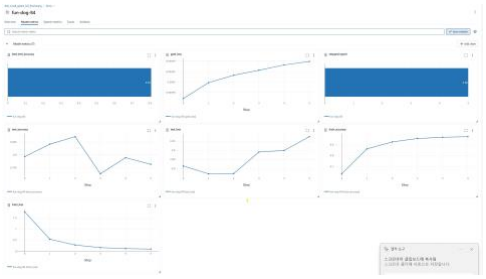


그림 4. Gated 모델 run overview

4.4 어텐션 맵 시각화 비교

본 연구의 핵심 결과는 어텐션 맵의 정성적 비교에서 나타난다. 그림 5는 baseline 모델의 12번째 layer에서 6개 헤드의 CLS-to-patch attention map을 시각화한 것이다. 어텐션이 객체(배구 선수)의 신체 영역이 아닌 배경의 산발적인 위치(이미지 우측 상단, 하단의 작은 점들)에 집중되는 전형적인 sink 패턴이 관찰되며, 이러한 점들은 의미 정보가 거의 없는 배경 패치들이다.

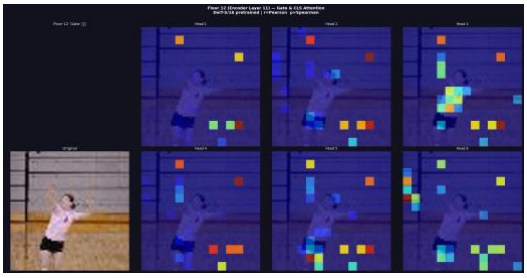


그림 5. Baseline 모델의 12번째 layer 어텐션 맵 (Sink 현상)

반면 그림 6은 동일한 입력에 대한 gated 모델의 어텐션 맵을 보여준다. 좌측 상단의 게이트 활성도 맵(all heads avg)은 게이트가 위치별로 차등적으로 동작함을 나타내며, 6개 헤드의 어텐션이 이전과 달리 객체(사람)의 신체 영역(머리, 상체, 팔, 다리)을 따라 의미 있게 분포함을 확인할 수 있다. 특히 Head 4와 Head 5는 사람의 윤곽을 따라 어텐션이 응집되어 있으며, 배경의 sink 패턴이 크게 감소하였다. 이는 게이트 메커니즘이 어텐션 헤드의 "기본 출력처" 의존을 효과적으로 완화하고, 어텐션을 의미 있는 토큰으로 재분배함을 시사한다.

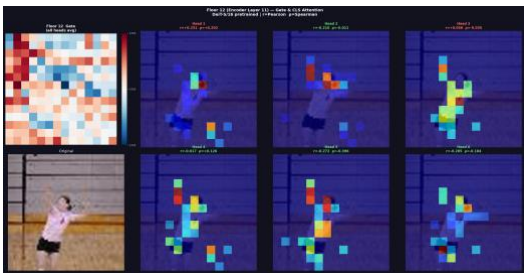


그림 6. Gated 모델의 12번째 layer 어텐션 맵 (객체 영역으로 응집)

5. 결론 및 향후 과제

본 연구는 사전학습된 DeiT-Small의 추가 학습 과정에서 나타나는 attention sink 현상을 완화하기 위해, 선행 연구에서 제안된 SDPA 이후 sigmoid gating 구조를 비전 Transformer 환경에 적용하였다. 구체적으로 multi-head self-attention에서 softmax가 적용된 후 head concat 직후 단계에 입력 의존적 시그모이드 게이트를 도입하고, 해당 구조가 이미지 분류 성능과 attention 분포에 미치는 영향을 분석하였다. 실험 결과, gated DeiT는 baseline과 유사한 분류 정확도(0.807 vs. 0.821)를 유지하면서도, attention map 시각화에서 특정 sink 토큰으로 과도하게 집중되던 attention이 객체 영역 중심으로 재분배되는 경향을 보였다. 이는 sigmoid gating이 어텐션 헤드에 불필요한 토큰 의존을 완화할 수 있는 추가적인 조절 자유도를 제공하며, 비전 Transformer에서도 attention sink 완화에 활용될 수 있음을 시사한다. 향후 연구에서는 (1) 더 긴 학습 epoch 및 다양한 데이터셋을 활용한 정량적 검증을 수행하고, (2) DeiT- Base와 같은 더 큰 모델로 실험 범위를 확장할 예정이다. 또한 (3) downstream 태스크 전이 성능 분석과 (4) 게이트 위치별 ablation study를 통해 gated attention의 효과와 적용 조건을 보다 체계적으로 분석할 계획이다.

참고문헌

[1] A. Dosovitskiy et al., "An Image is Worth 16x16 Words: Transformers for Image Recognition at Scale," in Proc. ICLR, 2021.

[2] H. Touvron, M. Cord, M. Douze, F. Massa, A. Sablayrolles, and H. Jégou, "Training data-efficient image transformers & distillation through attention," in Proc. ICML, vol. 139, pp. 10347–10357, 2021.

[3] G. Xiao, Y. Tian, B. Chen, S. Han, and M. Lewis, "Efficient Streaming Language Models with Attention Sinks," in Proc. ICLR, 2024.

[4] T. Darcet, M. Oquab, J. Mairal, and P. Bojanowski, "Vision Transformers Need Registers," in Proc. ICLR, 2024.

[5] Y. Bondarenko, M. Nagel, and T. Blankevoort, "Quantizable Transformers: Removing Outliers by Helping Attention Heads Do Nothing," in Advances in NeurIPS, 2023.

[6] X. Gu, T. Pang, C. Du, Q. Liu, F. Zhang, C. Du, Y. Wang, and M. Lin, "When Attention Sink Emerges in Language Models: An Empirical View," in Proc. ICLR, 2025.

[7] Z. Qiu et al., "Gated Attention for Large Language Models: Non-linearity, Sparsity, and Attention-Sink-Free," arXiv preprint arXiv:2505.06708, 2025.

[8] A. Vaswani et al., "Attention Is All You Need," in Advances in NeurIPS, 2017.

[9] Z. Yu, Z. Wang, Y. Fu, H. Shi, K. Shaikh, and Y. C. Lin, "Unveiling and Harnessing Hidden Attention Sinks: Enhancing Large Language Models without Training through Attention Calibration," in Proc. ICML, 2024.

[10] J. Deng, W. Dong, R. Socher, L.-J. Li, K. Li, and L. Fei-Fei, "ImageNet: A Large-Scale Hierarchical Image Database," in Proc. IEEE CVPR, pp. 248–255, 2009.